

BOLETIM DIÁRIO

Edição Técnica • Inteligência Artificial • Big Data • Arquitetura de Software

Segunda-feira, 25 de maio de 2026 • Ano 1 • Nº 142

INTELIGÊNCIA ARTIFICIAL

Modelos de linguagem menores ganham espaço em aplicações corporativas

25/05/2026 • Inteligência Artificial

Empresas que antes corriam atrás dos maiores modelos de linguagem disponíveis começam a migrar para modelos compactos, com menos de 10 bilhões de parâmetros, rodando em infraestrutura própria. A motivação principal é custo: rodar inferência localmente em tarefas repetitivas, como classificação de tickets e extração de dados, sai significativamente mais barato do que depender de APIs externas cobradas por token. Especialistas apontam que, para 70% dos casos de uso internos, um modelo pequeno e bem ajustado entrega qualidade equivalente à de modelos de fronteira, desde que combinado com técnicas de recuperação de contexto.

RAG continua sendo a abordagem dominante para reduzir alucinações

25/05/2026 • Inteligência Artificial

A técnica de Geração Aumentada por Recuperação, conhecida como RAG, permanece como o padrão de fato para ancorar respostas de modelos de linguagem em fontes confiáveis. Em vez de depender apenas do conhecimento interno do modelo, o sistema busca trechos relevantes em uma base de documentos e os injeta no prompt antes da geração. Engenheiros relatam que a qualidade do resultado depende muito menos do modelo em si e muito mais da etapa de recuperação: o particionamento dos documentos em pedaços, a escolha do modelo de embeddings e o ranqueamento dos trechos recuperados. Um erro comum é recuperar contexto demais, o que dilui a relevância e aumenta o custo, em vez de melhorar a resposta.

Avaliação de sistemas de IA migra de testes manuais para pipelines automatizados

24/05/2026 • Inteligência Artificial

Equipes de produto têm abandonado a avaliação manual e subjetiva de respostas geradas por IA em favor de conjuntos de avaliação versionados, com perguntas e respostas esperadas. A prática, batizada de 'evals', trata o comportamento do modelo como código: cada mudança no prompt ou na base de conhecimento dispara uma bateria de testes que mede precisão, fidelidade ao contexto e taxa de recusa. Sem essa disciplina, segundo os entrevistados, é impossível saber se um ajuste no prompt melhorou ou piorou o sistema como um todo.

Arquiteturas de lakehouse consolidam fusão entre data lake e data warehouse

25/05/2026 • Big Data

O modelo de lakehouse, que combina a flexibilidade do data lake com a governança e o desempenho do data warehouse, virou escolha padrão em novos projetos de dados. A proposta elimina a duplicação de dados entre dois sistemas separados, mantendo tudo em formato aberto sobre armazenamento de objetos barato. Formatos de tabela transacionais permitem operações de atualização e exclusão com garantias de consistência, algo que antes era exclusivo dos bancos tradicionais. A adoção, porém, exige maturidade em catalogação e controle de esquema, sem os quais o lakehouse rapidamente degenera em um 'pântano de dados' difícil de consultar.

Processamento em streaming supera batch em casos de uso sensíveis a tempo

24/05/2026 • Big Data

Pipelines que processam eventos em tempo real, à medida que chegam, ganham terreno sobre o processamento em lote tradicional em cenários como detecção de fraude e recomendação. A diferença central está na latência: enquanto o batch acumula dados e processa em janelas de horas, o streaming reage em segundos. A contrapartida é a complexidade operacional, já que sistemas de streaming precisam lidar com eventos fora de ordem, reprocessamento e garantias de entrega. Muitas equipes adotam uma abordagem híbrida, mantendo o batch para relatórios históricos e o streaming apenas onde o tempo de resposta é crítico.

Qualidade de dados se torna prioridade antes de qualquer iniciativa de IA

23/05/2026 • Big Data

Líderes de engenharia de dados alertam que investir em IA sobre dados de baixa qualidade é desperdício de recurso. O princípio de 'lixo entra, lixo sai' se aplica com ainda mais força a sistemas de recuperação de contexto: se a base de documentos contém informação desatualizada, duplicada ou mal estruturada, nenhum modelo de linguagem conseguirá compensar. A recomendação é tratar a curadoria da base de conhecimento como uma etapa de engenharia de primeira classe, com versionamento, validação de esquema e remoção de duplicatas antes de gerar embeddings.

Filas de mensagens seguem como espinha dorsal de sistemas desacoplados

25/05/2026 • Arquitetura de Software

Filas de mensagens permanecem como peça central em arquiteturas orientadas a eventos, isolando produtores de consumidores e permitindo que cada parte do sistema escale de forma independente. O padrão mais comum combina um tópico de publicação e assinatura, que distribui um evento para vários interessados, com filas individuais que garantem o processamento confiável de cada mensagem. Quando um consumidor falha, a mensagem retorna para a fila e pode ser reprocessada, e mensagens que falham repetidamente são desviadas para uma fila de mortos para inspeção posterior. Esse desacoplamento é o que permite, por exemplo, que um agendador publique resultados sem precisar saber quem vai consumi-los.

Padrão de agendador desacoplado ganha tração em automações periódicas

24/05/2026 • Arquitetura de Software

Em vez de embutir lógica de tempo dentro da aplicação, equipes têm extraído essa responsabilidade para um componente agendador dedicado. O agendador dispara em intervalos definidos, executa uma rotina — como reunir os dados do dia, montar um prompt e chamar um modelo de linguagem — e publica o resultado em uma fila. Essa separação torna o sistema mais testável e resiliente: o agendador não precisa conhecer os detalhes de quem processa a saída, e falhas em uma etapa não derrubam as demais. O padrão se encaixa bem com geração de relatórios, resumos diários e notificações recorrentes.

Idempotência volta ao centro das discussões em sistemas distribuídos

23/05/2026 • Arquitetura de Software

Garantir que processar a mesma mensagem duas vezes produza o mesmo resultado é apontado como requisito inegociável em arquiteturas baseadas em filas. Como a maioria dos sistemas de mensageria oferece entrega 'pelo menos uma vez', duplicatas são esperadas, não exceção. Estratégias como chaves de deduplicação, identificadores únicos por evento e verificações de estado antes de agir evitam efeitos colaterais como enviar o mesmo e-mail duas vezes ou cobrar um cliente em dobro. A ausência de idempotência costuma só aparecer em produção, sob carga, quando o problema é mais caro de resolver.

A convergência entre dados, IA e arquitetura define a próxima década

22/05/2026 • Análise

Cada vez mais, os três pilares deixam de ser disciplinas separadas. Um sistema moderno de IA é, antes de tudo, um sistema de dados bem arquitetado: a base de conhecimento precisa de engenharia de dados sólida, a recuperação de contexto precisa de infraestrutura de busca eficiente, e a orquestração precisa de padrões maduros de arquitetura, como filas e agendadores. Profissionais que dominam apenas uma das frentes encontram limites rápidos; o diferencial está em transitar entre as três.

Por que projetos pequenos ensinam mais que tutoriais longos

22/05/2026 • Opinião

Construir um sistema de ponta a ponta, mesmo simples, expõe decisões reais que tutoriais escondem: como particionar documentos, quando o contexto recuperado é suficiente, como lidar com uma fila que acumula mensagens. Um boletim diário automatizado, por exemplo, junta agendamento, recuperação de contexto, montagem de prompt e publicação em fila em um único fluxo enxuto. É justamente nesse tipo de projeto compacto que conceitos abstratos viram intuição prática.

Resumo da edição

Tema	Destaque do dia
Inteligência Artificial	Modelos menores e RAG dominam aplicações corporativas
Big Data	Lakehouse e streaming avançam; qualidade de dados é pré-requisito
Arquitetura de Software	Filas, agendadores e idempotência sustentam sistemas desacoplados